



本科生毕业论文（设计）

题目： 基于 VCSEL 光源的衍射设计网络架
构设计与研究

姓 名 邹超

学 号 22342109

院 系 微电子科学与技术学院

专 业 微电子科学与工程

指导教师 徐政基 副教授

2026 年 4 月 15 日

基于 VCSEL 光源的衍射设计网络架
构设计与研究

Design and Research of Diffraction
Neural Network Architecture Based
on VCSEL Light Source

姓 名	邹超
学 号	22342109
院 系	微电子科学与技术学院
专 业	微电子科学与工程
指导教师	徐政基 副教授

2026 年 4 月 15 日

学术诚信声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文（设计）不包含任何其他个人或集体已经发表或撰写过的作品成果。对本论文（设计）的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本论文（设计）的知识产权归属于培养单位。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日 期： 年 月 日

【摘 要】

基于衍射光学元件的光学深度学习在并行处理、计算速度和能效方面具有独特优势。自基于三维打印技术、工作在太赫兹频谱范围内的衍射深度神经网络(D2NN)被系统证明具有图像识别能力以来,D2NN的架构设计、训练方法和应用场景等方面的研究逐渐展开。与此同时,垂直腔面发射激光器(VCSEL)作为一种重要的半导体光源,在高速数据通信、三维感知和智能感知等领域获得了广泛应用。VCSEL的不同横模模式会显著影响其发散角、功率密度和系统性能,但由于其体积小、近场/远场观察困难,VCSEL模式识别成为一个挑战性问题。本文围绕VCSEL光源的模式识别任务,设计并实现了一套基于D2NN的建模与训练框架,并在多类任务上开展了验证与分析。通过引入量化感知训练(QAT)机制,显著提升了4级量化模型的性能,使其在实际器件制造约束下仍能保持较高的识别准确率。本文的研究不仅为VCSEL模式识别提供了一种新的智能算法架构,也为衍射神经网络在实际工程应用中的设计与优化提供了有益的参考。

关键词: 衍射神经网络, 垂直腔面发射激光器, 横模识别, QAT, 相位量化

[ABSTRACT]

Optical deep learning based on diffractive optical elements has unique advantages in parallel processing, computational speed, and energy efficiency. Since the three-dimensional printed, terahertz spectrum-operating diffractive deep neural network (D2NN) was systematically demonstrated to possess image recognition capabilities, research on the architectural design, training methods, and application scenarios of D2NN has gradually expanded. Meanwhile, as an important semiconductor light source, vertical cavity surface emitting lasers (VCSELs) have found widespread applications in high-speed data communication, 3D sensing, and intelligent perception.

The different transverse mode patterns of VCSELs significantly affect their divergence angle, power density, and system performance. However, due to their small size and the difficulty in observing near-field/far-field characteristics, VCSEL mode identification has become a challenging issue. This study focuses on the mode identification task of VCSEL light sources, designing and implementing a modeling and training framework based on D2NN, and conducting verification and analysis on multiple tasks. By introducing a quantization-aware training (QAT) mechanism, the performance of the 4-level quantized model was significantly improved, allowing it to maintain high recognition accuracy under practical device manufacturing constraints.

This research not only provides a new intelligent algorithm architecture for VCSEL mode identification but also offers valuable insights for the design and optimization of diffractive neural networks in practical engineering applications.

Key Words: Diffraction Neural Network; Vertical-Cavity Surface-Emitting Laser; Transverse Mode Recognition; QAT; Phase Quantization

目 录

第 1 章 绪论	1
1.1 选题背景与意义	1
1.2 国内外研究现状	2
1.2.1、VCSEL 发展现状	2
1.2.2、D ² NN 发展现状	3
1.3 论文结构安排	4
第 2 章 VCSEL 横模与衍射神经网络基础	5
2.1 VCSEL 及其光场模式	5
2.2 标量衍射与角谱传播理论	6
2.3 衍射神经网络基础	7
2.3.1、衍射传播层	7
2.3.2、前向传播模型与误差反向传播	8
2.3.3、可训练衍射层	9
2.3.4、探测器层与误差反向传播	9
第 3 章 模型与训练方法及实验	12
3.1 D ² NN 模型	12
3.2 实验环境与开发平台	13
3.3 训练与优化方法	14
3.3.1、QAT 机制	14
3.3.2、损失函数	15
3.3.3、Adam 优化器	15
第 4 章 实验结果分析与器件可行性	17
4.1 数字识别与 VCSEL 模式识别	17
4.2 混淆矩阵与相位	18
4.3 相位量化与高度转化	19
4.4 可训练相位层的制备方法	20
第 5 章 总结与展望	22
5.1 全文总结	22
5.2 研究不足与改进方向	22

5.3 未来展望	22
参考文献	24
致谢	25

第 1 章 绪论

1.1 选题背景与意义

随着人工智能、光通信和神经网络的快速发展，信息处理系统对计算速度、能耗和并行处理能力提出了越来越高的要求。传统电子计算架构在复杂神经网络推理任务中具有较高的准确率和成熟的软件生态，但其运行速度仍受到时钟频率、存储访问和数据搬运的限制，功耗高的同时伴随着发热严重的问题。近年来，利用光在传播过程中的衍射、干涉和并行传输特性进行计算，光学神经网络与光子学推理系统逐渐成为智能信息处理研究中的一个重要方向^[1]。

在众多光学神经网络实现方案中，衍射神经网络（Diffractive Deep Neural Network, D²NN）因其结构直观、易于物理实现和计算过程天然并行而受到广泛关注。2018 年，Ozcan 等人在 Science 上发表《All-optical machine learning using diffractive deep neural networks》，文中实现了通过多层衍射单元调制入射光场，可以在纯光域内完成数字识别、图像分类等任务^[2]。Liu 等人的研究进一步扩展了衍射神经网络的可编程性、集成性和任务适应性，例如基于数字编码超表面的可编程衍射深度神经网络，已能够完成图像分类、通信解码和实时多波束聚焦等任务^[3]。这些研究表明，衍射神经网络不仅具有基础理论价值，也具有面向实际应用的系统设计潜力。




图 1.1 D²NN 的发展。A Ozcan 团队设计的 D²NN 结构；B Lin 等人设计的可编程 D²NN；C Ning, Y.M 等人设计的引入非线性的 D²NN。

垂直腔面发射激光器（Vertical-Cavity Surface-Emitting Laser, VCSEL）作为一

种重要的半导体光源，因其结构紧凑、响应速度快、易于二维阵列集成、成本低和能效高等优势^[4]，在高速数据通信、三维感知、ToF 深度探测、车载 LiDAR、消费电子和智能感知等领域获得了广泛应用^[5-6]，其中人脸 3D 识别更是成为苹果公司 iPhone 系列手机的一大特点^[6]。

对于激光器而言，不同横模、近场分布和远场分布会显著影响光束发散角、功率密度、耦合效率、信道性能和系统稳定性。例如，在 LiDAR 与三维感知系统中，较低发散角、更好的模式纯度和更稳定的远场特性对于提升亮度、探测距离和系统分辨率至关重要^[5]。

VCSEL 在易于集成的同时，其体积小特点也使得观察识别 VCSEL 横模模式变得尤为困难。在实验室用显微镜观察 VCSEL 时，其远场光通常伴随着大量的背景噪声和衍射现象，如图1.2所示，近场观察时又不易记录所处横模状态。本文围绕 VCSEL 光源模式识别任务开展衍射神经网络架构设计与研究，不仅具有一定的理论价值，也能利用衍射神经网络解决研究 VCSEL 时其横模状态识别困难的问题，从而进一步利用 VCSEL 的不同横模特征并结合衍射神经网络，具有面向工程应用的现实意义。




图 1.2 实验室观察 VCSEL 横模远场时的图样

1.2 国内外研究现状

1.2.1 VCSEL 发展现状

VCSEL 是半导体激光器的重要分支，其发光方向垂直于晶圆表面，便于片上测试、阵列集成和大规模制造。近些年，随着数据中心互连、三维传感与车载光探测需求的提升，VCSEL 器件在高功率、高亮度、低发散角和高模式稳定性方面取得了显著进展。如图1.3所示，Zhang C 等人的研究表明，抗反射腔 VCSEL (AR-

VCSEL) 通过重新设计腔结构, 可在保持单纵模工作的同时显著减小发散角, 并在多结阵列中实现较高亮度和较优束质^[5]。

除效率提升外, VCSEL 的束形控制与模式工程也是当前研究热点。将介质超表面与 VCSEL 单片集成的方法, 实现了准直、Bessel 光束、涡旋光束等多种可编程发射模式^[7]。这些成果说明, VCSEL 已从传统光源器件逐步发展为可与微纳光学、波前工程和智能感知深度融合的平台。与此同时, 这也意味着对 VCSEL 模式特征进行有效识别与分类, 已成为器件设计优化、光束质量评估和系统控制的重要前提。




图 1.3 VCSEL 的应用与发展

不过, 从应用层面看, VCSEL 模式研究目前仍更多集中于器件结构设计、发散角优化、功率提升和束形调控, 围绕近场/远场光斑模式自动识别所展开的通用智能算法架构研究相对较少。尤其是在将光学传播模型与智能识别模型统一起来的方向上, 仍具有较大的研究空间。

1.2.2 D²NN 发展现状

2018 年, Xing Lin 等人发表了一种基于衍射深度神经网络 (Diffraction Deep Neural Network, D²NN) 的全光机器学习框架, 其提出的 D²NN 通过训练多个衍射层上的相位或振幅调制单元, 使入射光在传播过程中完成任务相关的空间变换, 并将不同类别的结果映射到输出探测区域, 并通过激光直写、3D 打印等技术制作器

件进行实验验证^[2]。这一工作证明了衍射传播本身可以承担“网络层”的功能，是光学计算与深度学习结合的重要里程碑。后续研究又从可编程性、器件实现和非线性增强等方面拓展了 D²NN。

Hang Chen 等人在 2020 年提出的 D²NN 逻辑框架将衍射神经网络的工作范围拓展到了可见光波段，提出了包含修正公式的通用理论，解决了工作波长、神经元尺寸和制造限制之间的矛盾，大大增加了衍射神经网络的实用性^[8]。Liu C 等人的工作实现了可编程衍射深度神经网络，使系统可以在同一硬件平台上适应多种任务^[3]；Ning Y. M 等在 2025 年的研究则进一步表明，引入可编程 ReLU 非线性后，多层非线性衍射网络的分类性能可得到改善^[9]。Min Gu 等人的研究提出了一种互学习知识蒸馏框架（MLODNN），通过光学学生网络与电子或光学教师网络之间的双向知识传递，显著提升了光学衍射神经网络的分类精度与训练效率，尤其在小参数、复杂数据集上表现优异，为光电混合计算和全光学智能系统奠定了基础^[10]。

1.3 论文结构安排

本文以 VCSEL 光源模式识别为主要应用背景，围绕衍射神经网络架构设计展开研究。结合项目已有实现，本文重点开展以下几个方面的工作：

（1）构建面向 VCSEL 模式识别的统一任务框架。围绕 VCSEL 横模模式识别任务，根据 HG 理论与实验室实际观察到的现象设计统一的数据输入与预处理流程，将灰度图样映射为适用于衍射传播建模的光场振幅分布。

（2）建立基于角谱传播理论的衍射神经网络结构。依据标量衍射与傅里叶光学理论，构建包含自由传播层、透镜层、相位调制层和探测器层的 D²NN 模型，研究多层衍射调制下光场能量重分布与分类输出之间的关系。

（3）研究适用于 VCSEL 模式识别的探测器输出机制与训练策略。采用多探测器区域积分方式构造分类输出，结合交叉熵损失与分阶段训练方法，实现相位参数和层间距离参数的优化，并评估近场任务中的分类性能。

（4）开展相位量化与器件实现映射研究。针对衍射光学器件实际制备需求，对训练后的连续相位进行多级量化分析，研究其对识别性能的影响，并进一步实现相位到刻蚀深度的映射、高度图导出与器件参数提取，为后续 Lumerical FDTD 仿真和物理实现提供基础。

概括而言，本文希望解决的问题不是单一数据集上的分类，而是提出一种以 VCSEL 光源模式识别为主线、兼顾任务扩展与器件实现的衍射神经网络架构。

第 2 章 VCSEL 横模与衍射神经网络基础

2.1 VCSEL 及其光场模式

垂直腔面发射激光器（Vertical-Cavity Surface-Emitting Laser, VCSEL）是一类出光方向垂直于晶圆表面的半导体激光器，其原理图如图2.1所示。由于其易于阵列化集成、便于片上测试、封装成本低、可实现高速调制等特点，VCSEL 已在数据通信、三维传感与 LiDAR 等应用中成为关键光源之一^[5-6]。近年来的研究显示，通过腔结构优化与器件工程设计，VCSEL 在高亮度、低发散角与束质改善方面持续推进，体现出对光束质量与模式控制的迫切需求。




图 2.1 VCSEL 结构示意图

从“波前工程/束形控制”的角度，Xie, YY 等人的 VCSEL+ 超表面工作表明，通过在出光端引入相位结构（超表面），可以显著改变远场光束形态（准直、Bessel、Vortex 等），这从侧面说明：近场的相位/振幅结构与远场光束形态之间存在明确映射关系，因此近场与远场模式都可以作为模式识别的有效输入表征^[11]。

在近轴近似条件下，稳定谐振腔的横向本征模式可用厄米特-高斯（Hermite-Gaussian）形式表示。镜面处（或等效参考平面处）第 (m, n) 阶横模的横向场分布

可写为 Hermite 多项式与高斯包络的乘积，并在 x 与 y 方向可分离^[12]：

$$U_{mn}(x, y, z) = A_{mn}(z) H_m\left(\sqrt{2}\frac{x}{w(z)}\right) H_n\left(\sqrt{2}\frac{y}{w(z)}\right) \exp\left(-\frac{x^2 + y^2}{w(z)^2}\right) \quad (2.1)$$

其中 $H_m(\cdot)$ 为 Hermite 多项式， $w(z)$ 为光斑半径， $A_{mn}(z)$ 为幅度归一化因子。基模 ($m = n = 0$) 对应 TEM_{00} 的高斯分布。激光横模从基模到 2 阶模的示意图如图 2.2 所示，模阶数增加将引入更多横向节点并形成多瓣强度花样。




图 2.2 激光横模光场分布示意图

本文研究的衍射神经网络方法属于“以光场传播为计算载体”的智能推理框架。与传统电子卷积网络不同，其分类依据可直接与光场能量重分布过程建立联系，这也是本文将 VCSEL 模式作为对象的优势之一。

2.2 标量衍射与角谱传播理论

在许多自由空间传播与成像分析中，当偏振效应可忽略、传播介质均匀且满足近轴或弱聚焦条件时，可采用标量衍射理论描述光场传播。标量衍射理论的核心思想是：在给定初始平面光场（复振幅）后，光场在自由空间中的传播可通过传播算子计算得到。

在光学神经网络与衍射神经网络研究中，这类传播模型常被用作网络的“线性层”，并与可训练的相位调制面共同构成端到端可训练的物理网络。

角谱法（Angular Spectrum Method, ASM）是一种常用的自由空间传播计算方法。其基本形式可写为：

对输入平面复振幅 $U(x, y, 0)$ 做二维傅里叶变换得到空间频谱（角谱）：

$$A(f_x, f_y, 0) = \mathcal{F}\{U(x, y, 0)\} \quad (2.2)$$

传播距离为 z 后，频谱乘以传播传递函数：

$$A(f_x, f_y, z) = A(f_x, f_y, 0) \cdot H(f_x, f_y, z) \quad (2.3)$$

其中传播传递函数可写为（连续形式）：

$$H(f_x, f_y, z) = \exp \left[jkz \sqrt{1 - (\lambda f_x)^2 - (\lambda f_y)^2} \right] \quad (2.4)$$

其中 $k = 2\pi/\lambda$ 。

再对传播后的频谱做逆傅里叶变换得到输出平面场：

$$U(x, y, z) = \mathcal{F}^{-1} \{ A(f_x, f_y, z) \} \quad (2.5)$$

在数值实现中，通常采用 FFT/IFFT 并结合频谱中心化（fftshift）实现高效计算。本项目中衍射层与传播层就是以该方式实现：FFT 乘以相位传播因子 IFFT。

角谱法与衍射神经网络的结合，使得“自由空间传播”可作为网络层的一部分参与端到端训练，从而实现“物理传播 + 可训练相位”的联合优化，这是 D²NN 的基本思想。

2.3 衍射神经网络基础

D²NN (Diffractive Deep Neural Network) 是一类利用多层衍射结构实现推理与分类的光学神经网络。与传统电子神经网络不同，D²NN 的“层”对应物理意义上的传播与衍射调制：输入光场在多层衍射单元之间传播，每层单元对光场进行相位（或振幅）调制，最终在输出平面形成与任务相关的能量分布。分类任务可通过输出平面上不同区域的光强分布来判决。

Ozcan 团队的工作首次系统证明了该框架可用于手写数字等分类任务，并通过实验实现了物理衍射网络样机，表明这种架构能够以“光速”完成前向推理过程^[2]。

2.3.1 衍射传播层

D²NN 将自由空间中的标量衍射传播视为网络中相邻两层之间的连接权重。根据瑞利-索末菲（Rayleigh-Sommerfeld）衍射方程，可以将某一 D²NN 层中的每一个神经元视为一个二次波源，其到空间任意点的球面波传播可写成


$$w_l^i(x, y, z) = \frac{z - z_i}{r^2} \left(\frac{1}{2\pi r} + \frac{1}{j\lambda} \right) \exp \left(j \frac{2\pi r}{\lambda} \right) \quad (2.6)$$

其中， l 表示网络的第 l 层， i 表示位于第 l 层、坐标为 (x_i, y_i, z_i) 的第 i 个神经元；

$$r = \sqrt{(x - x_i)^2 + (y - y_i)^2 + (z - z_i)^2}, \quad j = \sqrt{-1}$$

该二次波的振幅和相对相位由两部分的乘积共同决定：一是入射到该神经元的输入波，二是该神经元的透射系数 t 。两者均为复值函数。

在离散网络中，下一层某个神经元处的入射场，可以看作上一层所有神经元二次波源的叠加。因此，衍射传播层在数学上对应一个复数值线性算子（复加权


 图 2.3 光在 D^2NN 中的传播

求和), 其权重由衍射传播核 w 决定, 且与层间几何距离、采样间隔等物理参数相关。

而在数值实现与深度学习训练中, 为提高计算效率, 衍射传播常采用频域传播算子, 如角谱法 (Angular Spectrum Method, ASM) 实现。设某平面复振幅为 $U(x, y, 0)$, 传播距离为 z 后的复振幅可写为

$$U(x, y, z) = F^{-1} \{ F[U(x, y, 0)] \cdot H(f_x, f_y, z) \} \quad (2.7)$$

其中 F 表示二维傅里叶变换, $H(f_x, f_y, z)$ 为传播传递函数, 一种常见形式为

$$H(f_x, f_y, z) = \exp \left(j k z \sqrt{1 - (\lambda f_x)^2 - (\lambda f_y)^2} \right), \quad k = \frac{2\pi}{\lambda}. \quad (2.8)$$

角谱法的表达与“空间域二次波源叠加”在离散条件下具有一致的物理含义, 但能通过 FFT/IFFT 在 GPU 上高效实现, 从而便于将传播层作为可微分模块纳入端到端训练流程。

此外, 本文默认照明为单色相干光, 因此层间复振幅满足相干叠加关系; 若进一步考虑空间/时间非相干情形, 可通过随机相位叠加、模态分解或基于点扩散函数 (PSF) 的卷积似等方法扩展建模。

2.3.2 前向传播模型与误差反向传播

D^2NN 的单层操作由“相位调制 + 自由空间传播”构成。设第 l 层相位调制函数为 $t_l(x, y)$, 则第 l 层调制后的复振幅可写为 Hadamard 乘积:

$$U'^l(x, y) = U_l(x, y) \odot t_l(x, y) \quad (2.9)$$

相邻层之间通过传播算子 $\mathcal{P}_{d_l}(\cdot)$ (传播距离为 d_l) 连接, 因此

$$U_{l+1}(x, y) = \mathcal{P}_{d_l} \{ U'^l(x, y) \} \quad (2.10)$$

式 (2.9)–(2.10) 给出了 D^2NN 从输入平面到输出平面的前向传播递推形式。该形式与神经元二次波源的叠加表达在物理意义上等价: 若将平面离散为神经元集合, 则某一层神经元的入射复振幅可由上一层所有神经元输出场在该点处相干叠加得到, 而每个神经元的输出场由传播响应与本层透射系数共同决定。

2.3.3 可训练衍射层

在 D^2NN 中，每个神经元不仅会产生二次波源，还包含一个可训练的透射系数 (transmission coefficient)，用于调制该神经元输出波的振幅与相位。第 l 层第 i 个神经元在空间点的输出波函数可写为

$$n_l^i(x, y, z) = w_l^i(x, y, z) t_l^i(x_i, y_i, z_i) \sum_k n_{l-1}^k(x_i, y_i, z_i) \quad (2.11)$$

$$m_l^i(x_i, y_i, z_i) = \sum_k n_{l-1}^k(x_i, y_i, z_i) \quad (2.12)$$

其中 w_l^i 为衍射传播响应， m_l^i 表示入射到该神经元的复振幅（由上一层所有神经元叠加而来，即相干叠加，complex-field superposition）， t_l^i 为该神经元的复数透射系数，是可训练参数。

其中透射系数还可进一步分解为

$$t_l^i(x_i, y_i, z_i) = a_l^i(x_i, y_i, z_i) \exp(j\phi_l^i(x_i, y_i, z_i)) \quad (2.13)$$

在纯相位 (phase-only) D^2NN 中，通常设 $a_l^i \approx 1$ ，将主要可训练自由度放在相位 ϕ_l^i 上，即

$$t_l(x, y) \approx \exp(j\phi_l(x, y)) \quad (2.14)$$

将式(2.9)代入式(2.6)，可得相位调制层的实现形式为

$$U'^l(x, y) = U_l(x, y) \odot \exp(j\phi_l(x, y)) \quad (2.15)$$

在训练过程中，为满足物理可实现性与可制造性约束，常将相位限制在有限区间。本文通过对无约束参数 $\theta_l(x, y)$ 施加 sigmoid 映射，使相位落在 $[0, \phi_{\max}]$ ：

$$\phi_l(x, y) = \phi_{\max} \cdot \sigma(\theta_l(x, y)), \quad \phi_{\max} \in \{\pi, 2\pi\} \quad (2.16)$$

其中 $\sigma(\cdot)$ 为 sigmoid 函数。该参数化方式不仅有助于训练稳定性，也便于后续引入相位离散化（多级相位台阶）与量化感知训练 (QAT) 等策略，以提升低比特相位部署时的性能鲁棒性。

2.3.4 探测器层与误差反向传播

D^2NN 的输出通常在输出平面通过探测器测量光强完成读出。输出平面复振幅为 $U_{M+1}(x, y)$ 时，其光强为

$$I(x, y) = |U_{M+1}(x, y)|^2 \quad (2.17)$$

在分类任务中，常将输出平面划分为 C 个探测区域 $\{c\}_{c=1}^C$ ，并将区域内光强积分作为类别得分 (logits)：

$$s_c = \sum_{(x,y) \in c} I(x, y), \quad c = 1, 2, \dots, C \quad (2.18)$$

从而得到 $\mathbf{s} = [s_1, \dots, s_C]$ 作为分类头的输出，与本文实现中关于 VCSEL 识别的 `detector_region_logits` 一致。

在分类任务中，常将输出平面划分为分区区域，每个区域对应一个类别，区域内光强积分作为该类得分 (logit)。本文实现中 `detector_region_logits(Int)` 正是将输出强度张量在预设探测区域内求和得到 $[(B, C)]$ 的 logits，这与上述探测强度建模是一致的。本文中的数字识别任务与 VCSEL 横模识别任务的探测器分布如图 2.4 所示。




图 2.4 探测器图样。a 数字识别任务中的 10 个探测区域。b VCSEL 横模识别任务的 5 个探测区域

误差反向传播 (Error Backpropagation)。为训练 D^2NN ，可定义损失函数度量输出与目标之间的偏差。以成像型 (imaging) D^2NN 为例，若在输出平面选取 K 个测量点，其测得强度为 s_k^{M+1} ，目标强度为 g_k^{M+1} ，可定义均方误差损失：

$$E(\Phi) = \frac{1}{K} \sum_{k=1}^K \left(s_k^{M+1} - g_k^{M+1} \right)^2 \quad (2.19)$$

将训练写为带相位约束的优化问题：

$$\min_{\Phi} E(\Phi), \quad 0 \leq \phi_i^l < 2\pi \quad (2.20)$$

为应用误差反向传播，需要计算损失对可训练相位的梯度。根据链式法则，损失对第 l 层第 i 个相位变量的梯度可写为

$$\frac{\partial E(\Phi)}{\partial \phi_i^l} = \frac{4}{K} \sum_{k=1}^K \left(s_k^{M+1} - g_k^{M+1} \right) \cdot \text{Re} \left\{ \left(U_k^{M+1} \right)^* \cdot \frac{\partial U_k^{M+1}}{\partial \phi_i^l} \right\} \quad (2.21)$$

其中 $(\cdot)^*$ 表示复共轭， Re 表示取实部。进一步地， $\frac{\partial U_k^{M+1}}{\partial \phi_i^l}$ 可按层间传播与相位调制的链式结构逐层递推计算。对于靠近输出端的层，该导数具有如下形式（写出

若干层作为示例)：

$$\frac{\partial U_k^{M+1}}{\partial \phi_i^M} = j t_i^M U_i^M w_{i,k}^M, \quad \frac{\partial U_k^{M+1}}{\partial \phi_i^{M-1}} = j t_i^{M-1} U_i^{M-1} \sum_{k_1} w_{k_1,k}^M t_{k_1}^M w_{i,k_1}^{M-1}. \quad (2.22)$$

并可推广到更前面的层：

$$\frac{\partial U_k^{M+1}}{\partial \phi_i^{M-L}} = j t_i^{M-L} U_i^{M-L} \sum_{k_1} \dots \sum_{k_L} w_{k_L,k}^M t_{k_L}^M \dots w_{k_1,k_2}^{M-L+1} t_{k_1}^{M-L+1} w_{i,k_1}^{M-L}. \quad (2.23)$$

其中 $(k_1, \dots, k_L)$ 为中间层神经元索引。

上述递推可基于“只有当索引匹配时偏导非零”的性质进一步简化，其关键结论可写为

$$\frac{\partial n_{k_2,k_1}^l}{\partial \phi_i^l} = \begin{cases} j t_i^l m_i^l w_{i,k_1}^l, & k_2 = i, \\ 0, & k_2 \neq i \end{cases} \quad (2.24)$$

式 (2.21)–(2.24) 说明 D^2NN 的训练可在误差反向传播框架下完成；在本文实现中，上述梯度计算由深度学习框架的自动微分机制完成，从而无需显式手工推导每层偏导。

第 3 章 模型与训练方法及实验

3.1 D²NN 模型

为实现对输入图案的端到端光学推理，本文构建并实现了一种基于波动光学传播的衍射神经网络（Diffractive Deep Neural Network, D²NN）。该网络由输入平面、若干个衍射传播-相位调制级联层以及输出探测平面组成。网络前向传播过程中，输入光场在自由空间传播算子的作用下在层间传递，并在每一衍射层通过可训练的相位分布对波前进行调制。输出端通过探测器阵列对光强分布进行读出，从而将不同类别映射到预设的空间区域。

在数值实现上，层间自由空间传播采用频域角谱法（Angular Spectrum Method, ASM）计算，以利用 FFT/IFFT 的高效性。可训练衍射层采用纯相位型调制（phase-only），即透射函数可写为

$$t(x, y) = \exp(j\phi(x, y))$$

为保证相位变量满足物理可实现约束，训练过程中通过 sigmoid 映射至 $[0, \phi_{\max}]$ ，对相位范围施加限制。在此基础上，本文进一步引入相位离散化与量化感知训练（QAT），使网络在训练阶段即可感知有限级相位台阶带来的量化误差，从而提高模型在相位量化后、仅包含有限相位级时的准确率^[13]。本文所用的模型主要参数如表3.1所示。

表 3.1 本文 D²NN 模型的各项参数

模型参数	MNIST 数字识别	VCSEL 近场识别 (+QAT)
波长 wl	632 nm	830 nm
epochs	5	30
Batch size	200	200
学习率 lr（主训练）	0.002	0.002
学习率 lr（细调）	1×10^{-6}	1×10^{-7}
Num_layers	3 层	3 层
Num_classes	10 类	5 类
loss 函数	MESloss	CrossEntropyLoss

在实验过程中，我们 VCSEL 远场图案进行了成像采集与初步分析。然而，与近场图案相比，远场强度分布极易受到成像光路等环境影响，在实用方面没有体现优秀的研究价值。具体而言，由于 VCSEL 在 x 与 y 方向存在横模特性，其远场分布可能包含多个分量的叠加，使得在未进行偏振选择时，部分低阶模式已呈现

多瓣结构。与此同时，远场成像在显微镜系统下易受到孔径截断、衍射、折射及像差等因素影响，导致采集到的图案包含明显的背景噪声并随实验条件产生漂移。上述因素使远场数据难以满足本文 D^2NN 训练所需的分布一致性与可复现性要求。因此，本文后续实验与模型验证主要基于 VCSEL 近场图案开展，远场结果仅作为补充现象观察与局限性讨论给出。

而对于 VCSEL 近场模识别，本文根据实验室实际拍摄 VCSEL 近场图片以及 Lumerical 仿真得到的光场分布，用 Python 模拟生成类似数据集用于模型训练，如图3.1所示。




图 3.1 本实验通过理论数据与实验实际拍摄效果制作用于训练的数据集

3.2 实验环境与开发平台

本文所有实验均基于 Python 与 PyTorch 实现，主要硬件与软件配置如表3.2所示，并在统一的软件与硬件环境下完成训练与评估。为确保不同设置间对比的公平性，本文在不同任务（数字识别、VCSEL 近场识别、加入了 QAT 机制的 VCSEL 近场识别）之间尽可能保持相同的模型骨架、传播求解方式与评价流程，仅在数据集、输出类别数与损失函数等必要环节进行适配调整。其中，用于训练的 VCSEL 模模样式图是根据实验室拍摄照片，用 Python 模拟生成的数据集。

输入数据统一转换为灰度图，并根据光场建模需要将强度图 $I(x, y)$ 映射为振幅输入 $E(x, y)$ （例如 $E = \sqrt{I}$ ），以与复振幅传播模型一致。训练过程中使用小批量随机梯度优化，验证阶段在固定验证集上统计分类准确率，并在必要时输出混淆矩阵与输出光场/探测器响应可视化结果。

表 3.2 实验硬件与软件开发平台

实验环境	名称	版本/型号
硬件	GPU	NVIDIA RTX 3060 Laptop
硬件	CPU	AMD Ryzen 7 5800H
软件	Python	3.12.12
软件	PyTorch	2.9.1+cu128

3.3 训练与优化方法

3.3.1 QAT 机制

在相位型 D^2NN 中，连续相位自由度能够提供较强的表达能力；然而在面向实际器件实现时，相位往往只能以有限级台阶形式实现（例如 4 级、8 级或 16 级）。若在训练完成后直接对连续相位进行后量化（post-training quantization），模型在低级数量化条件下可能出现显著的性能退化，甚至导致分类能力失效。为缓解上述问题，本文引入量化感知训练（Quantization-Aware Training, QAT）机制，使模型在训练阶段即显式考虑相位离散化误差，从而学习到对量化更稳健的相位分布^[13]。其标准流程如图 3.2 所示。




图 3.2 QAT 机制的标准流程图

具体而言，在前向传播中，将相位调制层的连续相位映射为有限级相位集合中的离散值；在反向传播中，通过可微近似或直通估计器（straight-through estimator, STE）使梯度能够回传并更新连续参数。训练完成后，模型相位可直接量化为目标级数用于验证与器件映射。本文通过与不使用 QAT 的基线模型进行对比，定量评估了 QAT 在 4 级量化等低比特条件下的性能增益，并进一步讨论了相位层数对量化鲁棒性的影响。

3.3.2 损失函数

在优化目标的设置方面,为使训练过程与 D^2NN 的物理读出形式保持一致,本文针对不同任务采用了不同的损失函数。需要强调的是, D^2NN 的输出端通常通过探测器对输出平面光强进行测量,而光强本质上是复振幅的模平方,因此损失函数的选择应与输出端的定义方式相匹配。

在损失函数的选择上,本文根据任务目标与输出读出形式进行匹配。对于数字识别任务,本文采用基于输出平面强度分布的均方误差损失 (MSELoss),将训练过程表达为输出强度

$$I(x, y) = |U(x, y)|^2$$

对预设目标强度分布 $G(x, y)$ 的逼近问题,从而驱动网络学习“将能量聚焦至目标区域”的相位调制策略。该设置在数字识别场景下能够获得稳定收敛。

然而,当本文将任务从数字识别扩展至 VCSEL 近场/远场模式识别时,若仍沿用相同的 MSELoss 目标形式,实验中观察到模型验证准确率长期维持在接近随机分布的水平,表明在该数据分布与任务设置下,基于像素级强度回归的监督信号不足以形成有效的类别判别梯度,训练过程难以从随机初始化中收敛到具有判别性的解。

为此,本文将 VCSEL 识别任务改为标准的分类学习表述:将输出平面预设探测区域的能量积分作为类别得分 (logits) s_c , 并采用交叉熵损失 (CrossEntropyLoss) 进行监督优化,以直接最大化正确类别与其它类别之间的判别间隔。该调整显著改善了训练稳定性,使模型能够在 VCSEL 模式识别任务上获得非随机的分类性能,并为后续相位量化与 QAT 机制的引入提供了可行的优化基础。

3.3.3 Adam 优化器

为高效训练具有大量可学习参数的模型,本文采用 Adam (Adaptive Moment Estimation) 优化器对目标函数进行迭代最小化。Adam 是一种将一阶动量与自适应学习率结合的随机梯度优化方法:它对梯度的均值与平方均值分别进行指数滑动平均估计,从而在不同参数维度上自动调整步长,在非平稳目标、稀疏梯度或噪声梯度场景下通常具有较好的收敛稳定性。

设待优化参数向量为 θ , 目标函数为 $J(\theta)$ 。在第 t 次迭代时,基于小批量数据计算梯度

$$g_t = \nabla_{\theta} J(\theta_t) \quad (3.1)$$

Adam 维护两个状态变量: 梯度的一阶矩估计 m_t 与二阶原始矩估计 v_t , 其更新为

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t \odot g_t \quad (3.2)$$

其中 $\beta_1, \beta_2 \in [0, 1)$ 为指数衰减系数, $\odot$ 表示逐元素乘法。由于初始化通常取 $m_0 = 0, v_0 = 0$, 在训练初期上述估计会偏向零, 因此 Adam 引入偏置校正:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}. \quad (3.3)$$

最终参数更新为

$$\theta_{t+1} = \theta_t - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (3.4)$$

在本文的 D^2NN 训练中, 待优化参数 θ 可对应为各衍射层的相位参数 (或其无约束参数化变量, 如 $\theta_l(x, y)$)。损失函数关于参数的梯度由自动微分获得, Adam 则用于在迭代中自适应调整不同像素/神经元相位参数的更新步长, 从而提升收敛速度与训练稳定性。

第 4 章 实验结果分析与器件可行性

4.1 数字识别与 VCSEL 模式识别

本文进行了数字识别、VCSEL 近场识别以及加入了 QAT 机制的 VCSEL 近场识别。其中 QAT 机制主要影响了总体准确率和 4/8 级相位量化后的准确率。本文实验采用了 MNIST 手写数据集训练用于识别数字的分类器，并在主要模型框架基本不变、仅对数据集、探测器、Loss 函数等方面修改的条件下，使用 6000 张 VCSEL 不同横模状态下近场光强分布图样训练用于识别 VCSEL 近场下横模模式的分类器。在此 VCSEL 识别基础上，本文还在训练过程中加入了 QAT 机制，以适应后续对相位层相位进行量化处理，提高相位在量化后的准确率。下图4.1分别为数字识别任务、VCSEL 横模识别任务、加入了 QAT 的 VCSEL 横模识别任务的样式图、探测器光分布图样和探测器光场强接收柱状图。




图 4.1 D^2NN 的识别结果。A 数字识别任务中对数字的识别。B VCSEL 横模识别对一阶模的识别。C 加入了 QAT 机制的 VCSEL 横模识别任务对二阶模的识别结果

本文在实验过程中还探讨了在 VCSEL 识别模型中可训练相位层的层数、不同

相位量化等级以及 QAT 机制对准确率的影响。表4.1展示了相同模型，不同层数和相同层数，加入 QAT 对准确率的影响。

表 4.1 不同实验参数对准确率的影响

	4layers	3 layers	3 layers (QAT)	2 layers (QAT)
original	94.54%	96.70%	85.60%	80.30%
4-level	12.37%	14.31%	66.52%	62.80%
8-level	68.76%	74.93%	83.43%	77.07%
16-level	90.65%	95.04%	84.38%	79.95%

根据实验测量，在相同条件下，3 层训练衍射层可以达到最佳准确率。在其他条件不变时，随着可训练衍射层的数量变化，最终准确率的稳定值为 3 层 > 2 层 > 4 层 > 5 层。未加入 QAT 机制之前，对模型相位进行 4、8 级量化后再利用测试集测试模型准确率，发现其准确率发生大幅度下降。而在加入 QAT 机制后，其最终稳定时的准确率对比未加入 QAT 机制时有约 10% 的准确率下降，但其在经过量化后再测试的准确率下降情况得到较好缓解，尤其是 4 级量化的准确率性能大幅提升。VCSEL 横模识别任务 (+QAT) 的损失与准确率在训练中的变化如图4.2所示。




图 4.2 VCSEL 横模识别任务 (+QAT) 的损失与准确率在训练中的变化

4.2 混淆矩阵与相位

下图4.3分别是 VCSEL 远场、VCSEL 近场、数字识别的混淆矩阵，以及 VCSEL 近场模型下的相位示意图。由于 VCSEL 远场光分布会受到显微镜、光折射、光衍射、背景噪声等影响，在 2 阶及高阶的训练里存在数据集制造困难，模型几乎无法准确分辨等问题，仅在分为基模、一阶模、高阶模三类时有一定的分辨效果，准确率为 96%。数字识别模型的准确率为 96%，3 层 D^2NN 对 VCSEL 近场识别的准确率为 96%，加入了 QAT 机制的 3 层 D^2NN 对 VCSEL 近场横模识别的准确率为 85%，2 层 D^2NN 对 VCSEL 近场横模识别的准确率为 80%。




图 4.3 混淆矩阵与相位。A VCSEL 横模远场识别的混淆矩阵。B VCSEL 横模近场识别的混淆矩阵。C 数字识别的混淆矩阵。D VCSEL 横模识别 (QAT) 训练出相位示例

4.3 相位量化与高度转化

为了使训练得到的相位层能够映射为可制造的衍射光学元件 (DOE) 或刻蚀结构, 需要建立相位延迟与结构高度之间的关系。考虑到实际器件制备很难涵盖所有相位转化后的高度需求, 本文主要将训练得到的相位量化归类为 4 类 $(0, \pi/4, \pi/2, 3\pi/4)$, 并将相位转化为高度分布。

对于折射率为 $n(\lambda)$ 的介质层, 在波长为 λ 时, 结构高度 $h(x, y)$ 引入的相位延迟可写为:

$$\Phi(x, y; \lambda) = \frac{2\pi}{\lambda} (n(\lambda) - 1) h(x, y) \quad (4.1)$$

若以中心波长 λ_c 为设计基准, 并希望高度范围覆盖 2π 的相位调制, 则最大高度可写为:

$$h_{\max} = \frac{\lambda_c}{n(\lambda_c) - 1} \quad (4.2)$$

进一步, 为了在训练中直接引入可制造约束, 可以将高度 (或等效相位) 参数化为一个受限权重矩阵 $W(x, y) \in [0, 1]$, 并令:

$$h(x, y) = h_{\max} W(x, y), \quad W(x, y) \in [0, 1] \quad (4.3)$$

该参数化方式的优点在于：训练变量天然满足制造范围约束，且可与后续的相位离散化（多级台阶）与量化感知训练（QAT）策略结合，以提升低比特相位实现时的性能保持能力。图4.4展示了 VCSEL 横模识别 (+QAT) 任务中所训练相位经过 4 级量化后的相位与高度展示图。




图 4.4 VCSEL 横模识别（QAT）4 级量化后的相位与转化的高度示意图

4.4 可训练相位层的制备方法

为实现衍射神经网络相位层的物理制备，可采用在二氧化硅（ SiO_2 ）基底上加工多级台阶结构的方式，将训练得到的连续相位分布映射为有限级（或高度）。Chen-H 等人的研究给出了一种典型的多级相位台阶流程：首先将网络训练相位约束在 $[0, \pi]$ 区间，并将相位离散为四个等级 $(0, \pi/4, \pi/2, 3\pi/4)$ ；随后在 SiO_2 晶圆上通过两次光刻-刻蚀叠加工艺实现四级高度台阶，从而得到对应的相位调制结构，制备步骤如图4.5所示。

在该方案中，根据高度转化公式，在 830 nm 波长的环境下，四个相位等级对应的刻蚀深度分别为：相位 $(0, \pi/4, \pi/2, 3\pi/4)$ 对应深度约为 $(676\text{ nm}, 451\text{ nm}, 225\text{ nm}, 0\text{ nm})$ 。为得到四种台阶高度，工艺采用两张光掩模（photomask）完成两轮图形转移与刻蚀叠加。整体流程可概括为以下步骤：

1. **基底清洗（Cleaning）**：选取双面抛光 SiO_2 晶圆作为基底，依次采用丙酮与异丙醇进行超声清洗，去离子水冲洗并以氮气吹干；随后可采用氧等离子体表面处理以进一步去除有机残留并改善表面洁净度。
2. **旋涂光刻胶（Spin-coating photoresist）**：在旋涂前对 SiO_2 表面进行 HMDS 预处理以增强光刻胶附着力；旋涂正性光刻胶并进行软烘（softbake），得到满足后续刻写与刻蚀要求的光刻胶厚度。




图 4.5 可训练相位层的制备步骤

3. **第一次刻写与显影 (Lithography and development, 1st)**: 使用第一张掩模进行曝光与显影, 通过后烘 (postbake) 改善显影效果, 使第一组图形窗口转移至光刻胶层并暴露对应的 SiO_2 表面区域。
4. **第一次刻蚀 (Etching, 1st)**: 采用等离子体刻蚀设备对暴露区域进行刻蚀, 得到第一阶深度 (文献中该轮刻蚀形成约 346 nm 的台阶深度, 用于构建 0 与 $\pi/4$ 相位对应的结构差异)。
5. **再次旋涂光刻胶 (Spin-coating photoresist, 2nd)**: 刻蚀后对样品进行清洗, 随后重复旋涂光刻胶与软烘步骤, 为第二轮图形转移做准备。
6. **第二次刻写与显影 (Lithography and development, 2nd)**: 使用第二张掩模进行曝光与显影, 使第二组图形与第一次刻蚀结构进行叠加对准, 实现对不同相位区域的进一步区分。
7. **第二次刻蚀 (Etching, 2nd)**: 再次进行等离子体刻蚀以叠加形成额外台阶深度 (文献中该轮产生约 225 nm 的附加深度)。两次刻蚀叠加后可得到四级高度: 676 nm, 461 nm, 225 nm, 0 nm。
8. **去胶与最终清洗 (Resist stripping and cleaning)**: 去除残余光刻胶并进行清洗处理, 得到最终多级台阶的衍射相位层结构。

上述方法通过“相位离散化 + 两次光刻刻蚀叠加”实现四级台阶结构, 具有工艺流程清晰、对准次数有限、适于批量加工等特点。对于本文研究的相位型 D^2NN , 该工艺提供了从训练相位到可制造器件结构的一条可行路径; 同时, 有限级相位台阶将引入量化误差, 因此需在训练阶段采用相位约束与量化感知训练 (QAT) 等策略以提升部署鲁棒性。

第 5 章 总结与展望

5.1 全文总结

本文围绕《基于 VCSEL 光源的衍射神经网络架构设计与研究》这一主题，针对 VCSEL 光源在不同工作模式下的图案表征与识别需求，结合衍射光学传播理论与深度学习优化方法，构建并实现了一套可训练的衍射神经网络 (Diffractive Deep Neural Network, D²NN) 建模与训练框架，加入了 QAT 机制以适应相位量化的需求，并在多类任务上开展了验证与分析。

5.2 研究不足与改进方向

尽管本文完成了 D²NN 架构设计与多任务验证，并在 QAT 改进量化性能方面取得了阶段性进展，但仍存在以下不足与可进一步研究的方向。

(1) 数据与任务方面：缺少真实测量数据的支撑。本文当前的 VCSEL 近场/远场识别主要基于模拟少数实验数据和理论制作的数据集开展验证，仍有必要进一步引入真实器件测试数据，并开展数据增强、噪声建模与域偏移分析，以提升模型在实际应用中的泛化能力。未来可结合实验平台采集真实 VCSEL 光斑图案，并在不同温度、电流、器件批次差异下验证模型鲁棒性。

(2) 结构与训练方面：需要形成更系统的架构消融与参数敏感性分析。本文已实现多任务模型与 QAT 机制对比，但仍可进一步从相位层数、层间距离、像素尺寸、波长等物理参数对性能的影响，通过更完整的对比实验与参数扫描，可进一步提升论文的研究深度与结论说服力。

(3) 量化与可制造性方面：QAT 仍需从“经验有效”走向“可解释与可优化”。尽管 QAT 显著改善了 4 级量化性能，但仍存在连续相位精度下降的现象。未来可进一步研究不同量化级数 (2/4/8/16/32/64) 与不同相位层数下 QAT 的理论最佳点与平衡实际制作的使用最佳模型，相位分布统计特性在 QAT 前后的变化；与器件工艺约束相一致的量化策略。这些工作将有助于建立“算法设计—量化约束—器件实现”的更稳定通路。

5.3 未来展望

未来需要引入更完整的 VCSEL 物理模型以复现高阶模。本文在 FDFD 中仅能基于简易等效模型观察到基模和一阶模，高阶模难以仿真复现。未来研究需要建立更完整的 VCSEL 3D 模型以用作 FDTD 仿真，并改进边界条件、网格设置与数

值稳定性策略。尝试本征模求解 (eigenmode) 或非厄米增益腔模态分析方法, 以提高对高阶模式的捕获能力; 当器件级仿真能够稳定复现多阶模式后, 可进一步将 D^2NN 训练得到的相位结构与器件模型联动, 实现从“网络训练”到“全波验证”乃至“实验制备”的闭环研究。

在完成仿真后需进一步面向物理实现与系统集成。未来可探索将训练好的相位层通过衍射光学元件、超表面或空间光调制器实现, 并在实际光路中验证 VCSEL 模式识别效果。同时, 通过研究 VCSEL 与 D^2NN 的结合, 未来希望可以研究以 VCSEL 作为光源时, 能在 VCSEL 不同的横模模态时, 令 D^2NN 展现出不同的功能, 提高系统的灵活性。

参 考 文 献

- [1] Wetzstein G, Ozcan A, Gigan S, et al. Inference in artificial intelligence with deep optics and photonics[J]. *Nature*, 2020, 588: 39-47.
- [2] Lin X, Rivenson Y, Yardimci N T, et al. All-optical machine learning using diffractive deep neural networks[J]. *Science*, 2018, 361(6406): 1004-1008.
- [3] Liu C, Ma Q, Luo Z J, et al. A programmable diffractive deep neural network based on a digital-coding metasurface array[J]. *Nature Electronics*, 2022, 5: 113-122.
- [4] 伊贺健一, 小山二三夫. 面发射激光器基础与应用[M]. 郑军, 译. 北京: 科学出版社, 2002.
- [5] Zhang C, Li H, Liang D. Antireflective vertical-cavity surface-emitting laser for lidar[J]. *Nature Communications*, 2024, 15: 1105.
- [6] Chou J B, Quack N, Wu M C. Integrated vcsel-microlens scanner with large scan range[J]. *Journal of Microelectromechanical Systems*, 2014, 23(6): 1471-1476.
- [7] 王秋华. 集成超构表面垂直腔面发射激光器研究[D]. 北京工业大学, 2021.
- [8] Chen H, Feng J, Jiang M, et al. Diffractive deep neural networks at visible wavelengths[J]. *Engineering*, 2021, 7(10): 1483-1491.
- [9] Ning Y M, Ma Q, Xiao Q, et al. Multilayer nonlinear diffraction neural networks with programmable and fast relu activation function[J]. *Nature Communications*, 2025, 16: 10332.
- [10] Ma X, Xia W, Qiu Z, et al. Mutual learning knowledge distillation framework for adaptive optimization of optical diffractive neural network[J]. *APL Photonics*, 2025, 10(11): 110802.
- [11] Xie Y Y, Ni P N, Wang Q H, et al. Metasurface-integrated vertical cavity surface-emitting lasers for programmable directional lasing emissions[J]. *Nature Nanotechnology*, 2020, 15: 125-130.
- [12] 周炳琨. 激光原理 (第 7 版) [M]. 北京: 国防工业出版社, 2014: 51-55.
- [13] Coelho C N, Kuusela A, Li S, et al. Automatic heterogeneous quantization of deep neural networks for low-latency inference on the edge for particle detectors[J]. *Nature Machine Intelligence*, 2021, 3: 675-686.

致 谢

光阴似箭，岁月如梭，一眨眼就到了毕业的时候了。第一次从鹭江地铁站走到中大南校东门的感觉就像还是不久之前，从走入中大的校门起，我开始了一段丰富充实的人生旅途。在中大的这一段时光里，我学到了很多知识和技能，认识到了许多能力强大而又谦逊的同学和老师，学会了珍贵的人生哲理和处世经验。

首先，我由衷地敬佩、感谢我的导师徐政基副教授。徐老师真的是一位有耐心、涵养出众的优秀老师，完美符合我心中的人民教师形象。当我因突然幸运地保研而不知所措时，是徐老师积极为我提供指导和帮助，让我顺利走完保研相关流程。在科研上，徐老师也提供了许多的见解和指导意见，帮我在混乱的实验中找对改进方向，并不断的鼓励我继续进步。

其次，我要感谢我的父母和哥哥。感谢我的家人们对我日常生活的关心，是他们为我提供了安稳的学习环境，为我在大学里取得的成就而高兴。我的家人始终是我最大的靠山，他们尊重我的每一个决策，并主动向我提供帮助，虽然相隔千里，但平时都会通过打视频、发微信联系，为我的未来规划指点迷津。

再次，我要感谢学校和学院提供的学习资源和科研平台以及任课老师们的敦敦教诲。感谢学校和学院提供的优质课堂资源、学习环境和科研平台，让我能自由地利用这些宝贵资源提升自己的科研和创新能力，拓展自己的科研视野和人生见识。感恩老师们在课堂上的倾囊相授，用自己的专业素养和优秀能力为我指明学习和科研的道路，让我学会如何正确的去钻研学问，如何克服眼前的困难继续前进。

最后，我要感谢组内的师兄师姐以及同学们。感谢师兄师姐在组会上仔细理解我的工作后，指出我存在的问题，并积极提供解决问题的思路，特别是郑再阳师兄、郑力天师兄、何政杰师兄以及韩珊珊师姐经常与我讨论，让我少走很多弯子，感谢师兄师姐们的悉心指导和无私帮助。我也感谢同学们丰富了我的大学生活，为我的大学生活增添了欢乐的色彩，陪伴我走过了精彩的大学四年。

2026 年 4 月